

Superresolução no Domínio de Frequências  
*Fine-tuning* do SATLAS com Focal Frequency Loss  
para Correção do Gap Espectral Planet–Aerofoto

Marcel Fernandes Gomes

PPGC – UFRGS  
CMP570 – Fotografia Computacional  
Prof. Manuel M. de Oliveira Neto  
Orientador: Prof. Dr. Eduardo S. L. Gastal


Junho de 2026

# Motivação: o *gap* espectral Planet → aerofoto

- Satélites comerciais de média resolução (PlanetScope,  $\approx 3$  m/px) carecem de **detalhe fino** frente a aerofotos ( $\approx 0,3$ – $0,5$  m/px).
- Esse *gap* aparece como **déficit de energia nas altas frequências** do espectro de potência (PSD).
- Limita aplicações que dependem de textura fina: infraestrutura urbana, cobertura vegetal, detecção de mudanças.

## Ideia central

Usar **superresolução por rede neural** para atenuar o *gap* — e medir o ganho *no domínio de frequências*.



PSD radial: todas as variantes ficam *abaixo* do GT nas frequências médias–altas.

# Pergunta e contribuição

## Pergunta

A **Focal Frequency Loss** (FFL) consegue empurrar um gerador ESRGAN a recuperar as frequências altas que o L1 e a *perceptual loss* tendem a suavizar?

**Abordagem:** *fine-tuning* do **SATLAS** (ESRGAN pré-treinado Sentinel-2  $\rightarrow$  NAIP,  $4\times$ ) com pares locais **Planet**  $\rightarrow$  **aerofoto**, adicionando a FFL como *loss* auxiliar espectral.

## Ablation study — 3 variantes

- **Baseline:** L1 + Perceptual + GAN (sem FFL)
- **FFL**  $\lambda = 0,1$ : FFL com peso baixo
- **FFL**  $\lambda = 1,0$ : FFL com peso alto

Avaliadas por **SSIM** (estrutura), **cPSNR** (reconstrução tolerante a *offset* inter-sensor) e **PSD\_L2** (distância espectral ao GT).

# Fundamentação: do gap à Focal Frequency Loss

## Caracterização do gap (Fourier 2D):

$$F[u, v] = \sum_{x, y} I[x, y] e^{-j2\pi(\frac{ux}{H} + \frac{vy}{W})}$$

PSD radial média  $P(r) = |F|^2$  integrada em anéis  $r = \sqrt{u^2 + v^2}$ . O *gap* = queda mais acentuada da PSD do Planet vs. aerofoto.

## Loss total

$$\mathcal{L} = \mathcal{L}_{L1} + \lambda_p \mathcal{L}_p + \lambda_G \mathcal{L}_G + \lambda_{FFL} \mathcal{L}_{FFL}$$

**Focal Frequency Loss** (Jiang et al., ICCV 2021):

$$\mathcal{L}_{FFL} = \frac{1}{MN} \sum_{u, v} w[u, v] |F_{\hat{I}}[u, v] - F_{HR}[u, v]|^2$$

- $w[u, v]$  = máscara **adaptativa**, atualizada a cada iteração.
- Frequências bem recuperadas:  $w \approx 0$ .
- Mal recuperadas (altas):  $w \approx 1 \Rightarrow$  recebem **mais gradiente**.

Reequilibra o gradiente que o L1 (dominado por baixas frequências) envia.

## Conexão com os tópicos de CMP570

| Tópico (CMP570)                  | Papel no projeto                                    |
|----------------------------------|-----------------------------------------------------|
| Aulas 12–13 — Fourier / DFT      | <code>torch.fft.fft2</code> no núcleo da FFL        |
| Aula 14 — Aliasing / Nyquist     | Motivação do gap espectral Planet/Sentinel          |
| Aula 15 — Teorema da Convolução  | Relação PSF $\leftrightarrow$ domínio de frequência |
| Semanas 10–11 — Filtro de Wiener | <i>Baseline</i> clássico de comparação              |

### Síntese

O trabalho leva os tópicos do curso a um problema real de sensoriamento remoto: **usar o domínio de frequências tanto como ferramenta de treino (FFL) quanto como métrica de avaliação (PSD\_L2).**

## Dados

- Entrada: PlanetScope (4 bandas, 3 m/px), RS.
- GT: aerofoto  $\approx 0,5$  m/px, mesma região.
- Chips  $32 \times 32$  (LR)  $\rightarrow 128 \times 128$  (HR), escala  $4\times$ , alinhados via GDAL/rasterio.

## FFL no SATLAS (2 patches, retrocompatíveis)

- `losses/basic_loss.py`: classe `FocalFrequencyLoss` no `LOSS_REGISTRY`.
- `models/ssr_esrgan_model.py`: campo opcional `ffl_opt` no YAML.

| Parâmetro                          | Valor                        |
|------------------------------------|------------------------------|
| Ponto de partida                   | <code>esrgan_16S2.pth</code> |
| Iterações                          | 20.000                       |
| Batch size                         | 4                            |
| LR inicial                         | $10^{-4}$ (decai 8k/16k)     |
| $N_s$ imagens/amostra              | 16                           |
| Chips treino/val                   | 1.476                        |
| $\lambda_{L1}/\lambda_p/\lambda_G$ | 1,0 / 1,0 / 0,1              |
| $\lambda_{FFL}$                    | 0 / 0,1 / 1,0                |


GPU Tesla V100-32GB, CUDA 12.9. Mesmo orçamento de treino (iter 20k fixo) para comparação justa.

## Resultado principal — FFL $\lambda = 1,0$ recupera frequências

| Variante          | SSIM $\uparrow$ | cPSNR $\uparrow$ | PSD_L2 $\downarrow$ |
|-------------------|-----------------|------------------|---------------------|
| Baseline          | 0,6352          | 29,09            | 0,2574              |
| FFL $\lambda=0,1$ | <b>0,6368</b>   | 29,08            | 0,2638              |
| FFL $\lambda=1,0$ | 0,6291          | 29,03            | <b>0,2389</b>       |

iter 20.000 — 1.476 chips.

- **PSD\_L2  $-7,2\%$**  vs. baseline — a FFL fecha parte do gap espectral.
- Custo **pequeno**:  $\Delta\text{SSIM} = -0,006$ ;  $\Delta\text{cPSNR} = -0,06$  dB.
- *Trade-off* favorável p/ fidelidade espectral.



SSIM (esq.) e PSD\_L2 (dir.):  $\lambda = 1,0$  tem o melhor equilíbrio espectral.

## Discussão — por que funciona (e por que $\lambda = 0,1$ não)

### Mecanismo

O L1 minimiza erro pixel a pixel, dominado pelas **baixas frequências** (maior energia  $\Rightarrow$  maior contribuição ao MSE). Resultado: estrutura grossa boa, **texturas finas suavizadas**. A FFL pondera o erro espectral de forma adaptativa e **redireciona o gradiente às frequências altas**.

- $\lambda = 1,0$ : o gerador “sacrifica” alinhamento estrutural (queda de SSIM) para ganhar energia em alta frequência (queda de PSD\_L2) — o *trade-off* típico espectral vs. espacial.
- $\lambda = 0,1$  **insuficiente**: o gap Planet $\rightarrow$ aerofoto é grande demais; o peso baixo não ativa o mecanismo focal.
- **Métrica espectral importa**: SSIM/PSNR não capturam o ganho — só o PSD\_L2 revela o efeito que a FFL visa corrigir.



# Conclusão e trabalhos futuros

## Resposta à pergunta central

**Sim:** a FFL com  $\lambda = 1,0$  reduz o PSD\_L2 em **7,2%** frente ao baseline, com custo de SSIM desprezível — confirmando que a *loss* espectral recupera frequências altas suavizadas pelas *losses* convencionais.

## Contribuições:

- 1 Integração retrocompatível da FFL ao SATLAS/BasicSR.
- 2 *Ablation* controlado (mesmo orçamento de treino) no domínio Planet→aerofoto.
- 3 Avaliação espectral (PSD\_L2) que expõe ganhos invisíveis a SSIM/PSNR.

**Trabalhos futuros:** pesos intermediários ( $\lambda = 0,3, 0,5$ ); mais dados / maior área (rodada 2 —  $\sim 9,4k$  chips em andamento); comparação com outros métodos guiados por frequência.

## Mensagem central

O domínio de frequências é, ao mesmo tempo, **a ferramenta** (FFL guiando o treino) e **a métrica** (PSD\_L2 medindo o gap). Ponderar o erro espectral de forma adaptativa basta para que um gerador ESRGAN recupere frequências altas que as *losses* espaciais deixam escapar.

**Obrigado!**

marcelgfernandes@gmail.com