

Superresolução no Domínio de Frequências *Fine-tuning* do SATLAS com Focal Frequency Loss para Correção do Gap Espectral Planet–Aerofoto

Marcel Fernandes Gomes


PPGC – UFRGS
CMP570 – Fotografia Computacional
Prof. Manuel M. de Oliveira Neto
Orientador: Prof. Dr. Eduardo S. L. Gastal

Junho de 2026

O que é o SATLAS?

Satlas Super-Resolution — AllenAI (Wolters et al., 2023)

- **Entrada:** série de 16 frames **Sentinel-2** (RGB, 32×32 px, ≈ 10 m/px)
- **Saída:** imagem super-resolvida $4\times$ (128×128 px, qualidade NAIP $\approx 2,5$ m/px)
- **Gerador:** ESRGAN / RRDBNet — 23 blocos RRDB, 48 canais de entrada (16 frames $\times$ 3 bandas)
- **Treinado em:** ~ 44 milhões de pares Sentinel-2 / NAIP (EUA, 2019–2020)



Exemplo SATLAS: Sentinel-2 (~ 10 m/px)
→ SR ($\sim 2,5$ m/px).

Estrada e bordas de mata invisíveis no LR,
nítidas no SR.

SATLAS na prática: *fine-tuning* para o domínio Planet

Treinamento original (S2 → NAIP):

- Sentinel-2: ~ 10 m/px, resposta espectral própria
- NAIP: ~ 1 m/px (EUA) — alvo do treino
- ~ 44 M pares cobrindo os EUA inteiros

Domain gap no nosso caso:

- Planet (~ 3 m/px) $\neq$ S2 em resposta espectral
- Aerofoto RS ($\sim 0,5$ m/px) $\neq$ NAIP em escala
- Zero-shot gera texturas incompatíveis com a região

Solução — *fine-tuning*:

- 1.476 chips locais Planet → aerofoto
- Corrige o domain gap com dados mínimos

Domínio original

Sentinel-2 (16 frames)
 ~ 10 m/px

↓ SATLAS pretrained

NAIP (EUA)
 ~ 1 m/px

Nosso domínio

PlanetScope (16 frames)
 ~ 3 m/px

↓ *fine-tuning*


Aerofoto RS
 $\sim 0,5$ m/px

Motivação: o *gap* espectral Planet → aerofoto

- Satélites comerciais de média resolução (PlanetScope, ≈ 3 m/px) carecem de **detalhe fino** frente a aerofotos ($\approx 0,3$ – $0,5$ m/px).
- Esse *gap* aparece como **déficit de energia nas altas frequências** do espectro de potência (PSD).
- Limita aplicações que dependem de textura fina: infraestrutura urbana, cobertura vegetal, detecção de mudanças.

Ideia central

Usar **superresolução por rede neural** para atenuar o *gap* — e medir o ganho *no domínio de frequências*.



PSD radial: todas as variantes ficam *abaixo* do GT nas frequências médias–altas.

Pergunta e contribuição

Pergunta

A **Focal Frequency Loss** (FFL) consegue empurrar um gerador ESRGAN a recuperar as frequências altas que o L1 e a *perceptual loss* tendem a suavizar?

Abordagem: *fine-tuning* do **SATLAS** (ESRGAN pré-treinado Sentinel-2 $\rightarrow$ NAIP, $4\times$) com pares locais **Planet** $\rightarrow$ **aerofoto**, adicionando a FFL como *loss* auxiliar espectral.

Ablation study — 3 variantes

- **Baseline:** L1 + Perceptual + GAN (sem FFL)
- **FFL** $\lambda = 0,1$: FFL com peso baixo
- **FFL** $\lambda = 1,0$: FFL com peso alto

Avaliadas por **SSIM** (estrutura), **cPSNR** (reconstrução tolerante a *offset* inter-sensor) e **PSD_L2** (distância espectral ao GT).

Fundamentação: do gap à Focal Frequency Loss

Caracterização do gap (Fourier 2D):

$$F[u, v] = \sum_{x, y} I[x, y] e^{-j2\pi(\frac{ux}{H} + \frac{vy}{W})}$$

PSD radial média $P(r) = |F|^2$ integrada em anéis $r = \sqrt{u^2 + v^2}$. O *gap* = queda mais acentuada da PSD do Planet vs. aerofoto.

Loss total

$$\mathcal{L} = \mathcal{L}_{L1} + \lambda_p \mathcal{L}_p + \lambda_G \mathcal{L}_G + \lambda_{FFL} \mathcal{L}_{FFL}$$

Focal Frequency Loss (Jiang et al., ICCV 2021):

$$\mathcal{L}_{FFL} = \frac{1}{MN} \sum_{u, v} w[u, v] |F_{\hat{I}}[u, v] - F_{HR}[u, v]|^2$$

- $w[u, v]$ = máscara **adaptativa**, atualizada a cada iteração.
- Frequências bem recuperadas: $w \approx 0$.
- Mal recuperadas (altas): $w \approx 1 \Rightarrow$ recebem **mais gradiente**.

Reequilibra o gradiente que o L1 (dominado por baixas frequências) envia.

Conexão com os tópicos de CMP570

Tópico (CMP570)	Papel no projeto
Aulas 12–13 — Fourier / DFT	<code>torch.fft.fft2</code> no núcleo da FFL
Aula 14 — Aliasing / Nyquist	Motivação do gap espectral Planet/Sentinel
Aula 15 — Teorema da Convolução	Relação PSF $\leftrightarrow$ domínio de frequência
Semanas 10–11 — Filtro de Wiener	<i>Baseline</i> clássico de comparação

Síntese

O trabalho leva os tópicos do curso a um problema real de sensoriamento remoto: **usar o domínio de frequências tanto como ferramenta de treino (FFL) quanto como métrica de avaliação (PSD_L2).**

Dados

- Entrada: PlanetScope (4 bandas, 3 m/px), RS.
- GT: aerofoto $\approx 0,5$ m/px, mesma região.
- Chips 32×32 (LR) $\rightarrow 128 \times 128$ (HR), escala $4\times$, alinhados via GDAL/rasterio.

FFL no SATLAS (2 patches, retrocompatíveis)

- `losses/basic_loss.py`: classe `FocalFrequencyLoss` no `LOSS_REGISTRY`.
- `models/ssr_esrgan_model.py`: campo opcional `ffl_opt` no YAML.

Parâmetro	Valor
Ponto de partida	<code>esrgan_16S2.pth</code>
Iterações	20.000
Batch size	4
LR inicial	10^{-4} (decai 8k/16k)
N_s imagens/amostra	16
Chips treino/val	1.476
$\lambda_{L1}/\lambda_p/\lambda_G$	1,0 / 1,0 / 0,1
λ_{FFL}	0 / 0,1 / 1,0


GPU Tesla V100-32GB, CUDA 12.9. Mesmo orçamento de treino (iter 20k fixo) para comparação justa.

Resultado principal — FFL $\lambda = 1,0$ recupera frequências

Variante	SSIM $\uparrow$	cPSNR $\uparrow$	PSD_L2 $\downarrow$
Baseline	0,6352	29,09	0,2574
FFL $\lambda=0,1$	0,6368	29,08	0,2638
FFL $\lambda=1,0$	0,6291	29,03	0,2389

iter 20.000 — 1.476 chips.

- **PSD_L2 $-7,2\%$** vs. baseline — a FFL fecha parte do gap espectral.
- Custo **pequeno**: $\Delta\text{SSIM} = -0,006$; $\Delta\text{cPSNR} = -0,06$ dB.
- *Trade-off* favorável p/ fidelidade espectral.



SSIM (esq.) e PSD_L2 (dir.): $\lambda = 1,0$ tem o melhor equilíbrio espectral.

Resultados visuais — região de condomínio (crop 192 px)



- **Planet (LR):** resolução ≈ 3 m/px — bordas e telhados sem definição.
- **SATLAS zero-shot:** sem *fine-tuning*, o modelo “acha” texturas do domínio Sentinel-2/NAIP — incompatíveis com a aerofoto RS.
- **Baseline e FFL $\lambda=0,1$:** *fine-tuning* recupera detalhe e corrige a paleta — resultado visualmente próximo.
- **FFL $\lambda=1,0$:** textura ligeiramente mais rica nas bordas e telhados — ganho espectral (+PSD_L2 -7,2%) visível nas altas frequências.

Resultados visuais — malha urbana densa (crop 192 px)



Segunda região confirma o padrão: **Planet** borrado, SATLAS zero-shot com artefatos de domínio, variantes *fine-tuned* nítidas. Diferenças entre Baseline / FFL $\lambda=0,1$ / FFL $\lambda=1,0$ são sutis visualmente — o ganho da FFL é *spectral* (PSD_L2), não pixelístico; por isso a métrica PSD_L2 é indispensável.

Discussão — por que funciona (e por que $\lambda = 0,1$ não)

Mecanismo

O L1 minimiza erro pixel a pixel, dominado pelas **baixas frequências** (maior energia $\Rightarrow$ maior contribuição ao MSE). Resultado: estrutura grossa boa, **texturas finas suavizadas**. A FFL pondera o erro espectral de forma adaptativa e **redireciona o gradiente às frequências altas**.

- $\lambda = 1,0$: o gerador “sacrifica” alinhamento estrutural (queda de SSIM) para ganhar energia em alta frequência (queda de PSD_L2) — o *trade-off* típico espectral vs. espacial.
- $\lambda = 0,1$ **insuficiente**: o gap Planet $\rightarrow$ aerofoto é grande demais; o peso baixo não ativa o mecanismo focal.
- **Métrica espectral importa**: SSIM/PSNR não capturam o ganho — só o PSD_L2 revela o efeito que a FFL visa corrigir.

Conclusão e trabalhos futuros

Resposta à pergunta central

Sim: a FFL com $\lambda = 1,0$ reduz o PSD_L2 em **7,2%** frente ao baseline, com custo de SSIM desprezível — confirmando que a *loss* espectral recupera frequências altas suavizadas pelas *losses* convencionais.

Contribuições:

- 1 Integração retrocompatível da FFL ao SATLAS/BasicSR.
- 2 *Ablation* controlado (mesmo orçamento de treino) no domínio Planet→aerofoto.
- 3 Avaliação espectral (PSD_L2) que expõe ganhos invisíveis a SSIM/PSNR.

Trabalhos futuros: pesos intermediários ($\lambda = 0,3, 0,5$); mais dados / maior área (rodada 2 — $\sim 9,4k$ chips em andamento); comparação com outros métodos guiados por frequência.

Mensagem central

O domínio de frequências é, ao mesmo tempo, **a ferramenta** (FFL guiando o treino) e **a métrica** (PSD_L2 medindo o gap). Ponderar o erro espectral de forma adaptativa basta para que um gerador ESRGAN recupere frequências altas que as *losses* espaciais deixam escapar.

Obrigado!

marcelgfernandes@gmail.com