

Universidade Federal do Rio Grande do Sul
Instituto de Informática
Programa de Pós-Graduação em Computação

Trabalho Final

Superresolução no Domínio de Frequências:

Fine-tuning do SATLAS com Focal Frequency Loss
para Correção do Gap Espectral Planet–Aerofoto

Fotografia Computacional (CMP570)
Prof. Manuel Menezes de Oliveira Neto
Orientador: Prof. Dr. Eduardo Simões Lopes Gastal

Aluno: Marcel Fernandes Gomes
Porto Alegre, 23 de junho de 2026

1 Introdução

Imagens de satélite comerciais de média resolução, como as do sensor PlanetScope (resolução espacial de ≈ 3 m/pixel), possuem limitações espectrais em relação a fotografias aéreas de alta resolução ($\approx 0,3$ – $0,5$ m/pixel). Esse *gap* se manifesta na ausência de frequências espaciais altas no espectro de potência (*Power Spectral Density*, PSD) das imagens Planet, quando comparado à PSD de aerofotos. Em aplicações que dependem de detalhe fino — como mapeamento de infraestrutura urbana, inspeção de cobertura vegetal e monitoramento de mudanças — essa diferença limita a utilidade operacional das imagens de satélite.

Superresolução por redes neurais oferece uma abordagem promissora para atenuar esse *gap*. O modelo SATLAS [2] fornece um gerador ESRGAN pré-treinado para o domínio Sentinel-2 $\rightarrow$ NAIP, com fator de escala $4\times$. Neste trabalho, realiza-se o *fine-tuning* desse modelo com pares locais Planet $\rightarrow$ aerofoto, e avalia-se o efeito de adicionar a **Focal Frequency Loss** (FFL) [1] como função de custo auxiliar no domínio espectral.

A FFL foi proposta por Jiang et al. (ICCV 2021) como uma *loss* que pondera erros no espaço de frequências de forma adaptativa: componentes espectrais que o gerador ainda não aprendeu a produzir corretamente recebem maior peso, direcionando o gradiente para a recuperação de frequências difíceis — tipicamente as de alta frequência que o L1 e a *perceptual loss* tendem a suavizar.

Contribuição

Realiza-se um *ablation study* com três variantes do *fine-tuning*:

- **Baseline:** L1 + Perceptual + GAN (sem FFL)
- **FFL $\lambda = 0,1$:** FFL adicionada com peso $\lambda = 0,1$
- **FFL $\lambda = 1,0$:** FFL adicionada com peso $\lambda = 1,0$

As variantes são comparadas por três métricas: SSIM (estrutural), cPSNR (reconstrutiva, tolerante ao *offset* inter-sensor) e PSD_L2 (distância espectral ao *ground truth*).

2 Fundamentação Teórica

2.1 Gap Espectral e Transformada de Fourier

O gap espectral entre imagens Planet e aerofotos pode ser caracterizado pela PSD radial média de cada imagem. Dado uma imagem I de dimensões $H \times W$, sua Transformada Discreta de Fourier 2D (DFT) é:

$$F[u, v] = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} I[x, y] e^{-j2\pi(\frac{ux}{H} + \frac{vy}{W})} \quad (1)$$

A PSD é definida como $P[u, v] = |F[u, v]|^2$, e a PSD radial é obtida integrando P em anéis de frequência $r = \sqrt{u^2 + v^2}$ (após centralização via *fftshift*). Imagens com maior riqueza de detalhes finos apresentam PSD radial com mais energia nas altas frequências. O *gap* Planet–aerofoto é visível como uma queda mais acentuada da PSD das imagens Planet em relação à PSD da aerofoto nas frequências médias–altas.

2.2 Focal Frequency Loss

A FFL opera no domínio de frequências. Dado o gerador G produzindo $\hat{I} = G(I_{LR})$ e o *ground truth* I_{HR} , define-se:

$$\mathcal{L}_{FFL} = \frac{1}{MN} \sum_{u,v} w[u, v] \cdot |F_{\hat{I}}[u, v] - F_{I_{HR}}[u, v]|^2 \quad (2)$$

onde F_X denota a DFT de X (calculada via `torch.fft.fft2`), e $w[u, v]$ é uma máscara de pesos adaptativa. Seguindo a implementação utilizada neste trabalho (`focal_frequency_loss.py`), a máscara é o módulo do erro espectral da iteração anterior, elevado a α e normalizado pela média, com `.detach()` (não participa do *backprop*):

$$w[u, v] = \frac{|\hat{F}[u, v] - F_{HR}[u, v]|^\alpha}{\mathbb{E}_{u,v} [|\hat{F} - F_{HR}|^\alpha] + \varepsilon} \quad (3)$$

onde α controla a agressividade do foco (tipicamente $\alpha = 1$). Componentes espectrais que o gerador já reproduz bem ($|\hat{F} - F_{HR}|$ pequeno) recebem peso baixo; as mal recuperadas (erro grande, tipicamente as altas frequências) recebem peso maior e mais gradiente. A loss total de treinamento é:

$$\mathcal{L}_{total} = \mathcal{L}_{L1} + \lambda_{perc} \mathcal{L}_{perc} + \lambda_{GAN} \mathcal{L}_{GAN} + \lambda_{FFL} \mathcal{L}_{FFL} \quad (4)$$

2.3 SATLAS e SSR-ESRGAN

O SATLAS é um modelo de superresolução multimodal para imagens de satélite. O gerador utilizado neste trabalho é o `SSR_RRDBNet`, uma variante do RRDB [3] adaptada para receber como entrada $N_s \times 3$ canais (empilhamento temporal de N_s imagens TCI), produzindo uma saída RGB com fator de escala $4\times$. O modelo foi pré-treinado com pares Sentinel-2 ($N_s = 16$) $\rightarrow$ NAIP com 20.000 iterações.

2.4 Conexão com os Tópicos de CMP570

Tabela 1: Conexão entre tópicos das aulas e elementos deste trabalho.

Tópico (CMP570)	Papel no projeto
Aulas 12–13 — Fourier / DFT	<code>torch.fft.fft2</code> no núcleo da FFL
Aula 14 — Aliasing / Nyquist	Motivação do gap espectral Planet/Sentinel
Aula 15 — Teorema da Convolução	Relação PSF $\leftrightarrow$ domínio de frequência
Semanas 10–11 — Filtro de Wiener	Baseline clássico de comparação conceitual

3 Metodologia

3.1 Dados

Os dados de entrada são imagens PlanetScope (4 bandas espectrais, 3 m/pixel) sobre uma região do estado do Rio Grande do Sul, obtidas via Planet Explorer. O *ground truth* é uma

aerofoto da mesma região com resolução de aproximadamente 0,5 m/pixel, disponibilizada pelo serviço de dados do estado.

O pré-processamento converte os TIFs Planet para chips de 32×32 pixels (resolução Planet) alinhados geometricamente com chips de 128×128 pixels do *ground truth* (aerofoto), resultando no fator de escala $4 \times$ esperado pelo modelo. O alinhamento é realizado por reprojeção via GDAL/rasterio, com reamostragem bilinear.

3.2 Implementação da FFL no SATLAS

A FFL foi integrada ao SATLAS como módulo adicional, com dois pontos de modificação:

- `ssr/losses/basic_loss.py`: implementação da classe `FocalFrequencyLoss` registrada via `@LOSS_REGISTRY.register()`, compatível com o sistema de *losses* do BasicSR.
- `ssr/models/ssr_esrgan_model.py`: suporte ao campo opcional `ffl_opt` nos YAMLS de configuração, inicializando `self.cri_ffl` e aplicando a loss em `optimize_parameters`. Retrocompatível: sem `ffl_opt`, o comportamento é idêntico ao original.

3.3 Configuração do Treinamento

O treinamento foi executado em servidor Linux com GPU Tesla V100-PCIE-32GB, CUDA 12.9. A Tabela 2 resume os hiperparâmetros comuns às três variantes.

Tabela 2: Hiperparâmetros de treinamento (comuns às três variantes).

Parâmetro	Valor
Ponto de partida	<code>esrgan_16S2.pth</code> (SATLAS pré-treinado)
Número de iterações	20.000
Batch size	4
Learning rate inicial	10^{-4} (decaimento em 8k e 16k iters)
Scheduler	MultiStepLR ($\gamma = 0,5$)
N_s (imagens Planet por amostra)	16
Chips de treinamento/validação	1.476
λ_{L1}	1,0
λ_{perc}	1,0
λ_{GAN}	0,1
λ_{FFL} (baseline)	—
λ_{FFL} (ffl_w01)	0,1
λ_{FFL} (ffl_w10)	1,0

3.4 Métricas de Avaliação

A avaliação compara as saídas SR de cada variante (iter 20.000) contra o *ground truth* (aerofoto) usando três métricas:

- **SSIM** (*Structural Similarity Index*): mede similaridade em luminância, contraste e estrutura. Maior é melhor.

- **cPSNR** (PSNR com ajuste afim por canal): tolerante ao *offset* radiométrico entre sensores diferentes (Planet vs. aerofoto). Para cada canal c , encontra-se a transformação afim $\hat{I}_c \leftarrow a\hat{I}_c + b$ que minimiza o MSE contra o GT, e reporta-se o melhor PSNR. Maior é melhor.
- **PSD_L2**: distância L2 no $\log_{10}$ do PSD radial médio entre a imagem SR e o GT, calculada canal a canal:

$$\text{PSD_L2} = \frac{1}{C} \sum_{c=1}^C \mathbb{E}_r \left[\left(\log_{10} P_{\hat{I},c}(r) - \log_{10} P_{GT,c}(r) \right)^2 \right] \quad (5)$$

Menor é melhor. Esta é a métrica principal do trabalho, por capturar diretamente o *gap* espectral que a FFL visa corrigir.

4 Resultados

4.1 Métricas Quantitativas

A Tabela 3 apresenta os resultados do *ablation study* para as três variantes, avaliadas no iter final (20.000).

Tabela 3: Resultados do ablation study — iter 20.000, 1.476 chips.

Variante	SSIM $\uparrow$	cPSNR (dB) $\uparrow$	PSD_L2 $\downarrow$
Baseline (sem FFL)	0,6352	29,09	0,2574
FFL $\lambda = 0,1$	0,6368	29,08	0,2638
FFL $\lambda = 1,0$	0,6291	29,03	0,2389

O principal resultado é que **FFL $\lambda = 1,0$ obtém o menor PSD_L2 (0,2389)**, representando uma redução de 7,2% em relação ao baseline (0,2574). Esse ganho espectral ocorre com um custo pequeno de SSIM ($\Delta = -0,0061$) e de cPSNR ($\Delta = -0,06$ dB), dentro da faixa de variação esperada. A variante com $\lambda = 0,1$ não produziu melhora expressiva em nenhuma métrica, indicando que o peso é insuficiente para que o mecanismo focal adaptativo da FFL direcione o treinamento de forma efetiva.

4.2 Comparação de Espectros de Potência




Figura 1: PSD radial média (escala log) das três variantes e do *ground truth*. Todas as variantes apresentam déficit de energia nas frequências médias-altas (0,1–0,5 ciclos/pixel) em relação ao GT, caracterizando o gap espectral. A diferença entre variantes é sutil nesta escala; o PSD_L2 quantifica numericamente a distância ao GT.

A Figura 1 mostra que todas as variantes seguem a mesma tendência: forte energia nas baixas frequências (estruturas grossas) e queda progressiva nas altas frequências. O *ground truth* (aerofoto) mantém maior energia nas frequências intermediárias (detalhes finos como bordas de edifícios, texturas de vegetação), refletindo a maior resolução espacial do sensor aéreo.

4.3 Comparação de Métricas por Barra




Figura 2: Comparação de SSIM (esquerda) e PSD_L2 (direita) entre as três variantes. FFL $\lambda = 1,0$ apresenta o melhor equilíbrio espectral (menor PSD_L2) ao custo de leve redução de SSIM.

4.4 Comparação Visual

As Figuras 3 e 4 apresentam comparações visuais de crops das imagens produzidas pelas três variantes, junto com a entrada Planet (LR ampliada $4\times$ por vizinho mais próximo) e a saída SATLAS sem fine-tuning (zero-shot). Os crops de 192×192 px foram selecionados em regiões de alta variância para evidenciar diferenças de detalhe.




Figura 3: Comparação visual — região de condomínio (crop 192×192 px no SR, ampliado para visualização). Da esquerda para a direita: Planet LR (upscale $4\times$ vizinho mais próximo), SATLAS zero-shot, Baseline (fine-tuning sem FFL), FFL $\lambda = 0,1$ e FFL $\lambda = 1,0$. O domain gap do zero-shot é evidente: textura e paleta incompatíveis com a aerofoto RS. O fine-tuning recupera detalhe local e corrige a paleta. FFL $\lambda = 1,0$ apresenta textura ligeiramente mais rica nas bordas e telhados, consistente com o ganho espectral medido pelo PSD_L2.



Figura 4: Comparação visual — malha urbana densa (crop 192×192 px). Mesmo padrão da Figura 3: Planet borrado, SATLAS zero-shot com artefatos de domínio, variantes fine-tuned nítidas e coerentes com a aerofoto. As diferenças visuais entre Baseline e variantes FFL são sutis, consistentes com os pequenos ΔSSIM e ΔcPSNR da Tabela 3. O ganho da FFL $\lambda = 1,0$ é primariamente espectral — capturado pelo PSD_L2, não pelo olho humano.



Figura 5: Visão geral da região de condomínio (crop 320×320 px) para as cinco variantes. A escala maior evidencia o ganho de estrutura do fine-tuning frente ao zero-shot, e o alinhamento de paleta com a aerofoto local (telhas terracota, vegetação verde).

4.5 Discussão

O resultado é consistente com o mecanismo da FFL. O L1 minimiza o erro pixel a pixel, o que penaliza erros em baixas frequências (que têm maior energia e portanto maior contribuição para o MSE) mais do que erros em altas frequências. Isso produz geradores que recuperam bem a estrutura grosseira da cena, mas suavizam as texturas finas. A FFL reequilibra esse gradiente: ao ponderar o erro no domínio de frequências de forma adaptativa, ela direciona o gerador para recuperar as componentes espectrais ainda mal aprendidas — tipicamente as de alta frequência.

O fato de $\lambda = 0,1$ não produzir melhora sugere que, neste domínio (Planet $\rightarrow$ aerofoto), o gap espectral é suficientemente grande para exigir um peso maior de FFL. Com $\lambda = 1,0$, o gerador efetivamente “sacrifica” algum alinhamento estrutural (queda de SSIM) para recuperar mais energia nas frequências altas (queda de PSD_L2) — o *trade-off* característico de losses espectrais versus espaciais.

5 Conclusões

Este trabalho demonstrou que a adição da Focal Frequency Loss ao *fine-tuning* do SATLAS com dados Planet $\rightarrow$ aerofoto produz melhora mensurável na fidelidade espectral da superresolução. Os principais achados são:

- **FFL $\lambda = 1,0$ reduz o PSD_L2 em 7,2%** em relação ao baseline, confirmando que a loss espectral direciona o gerador para recuperar frequências altas suavizadas pelas losses convencionais.
- **O custo de SSIM é pequeno** ($\Delta = -0,006$), sugerindo que o *trade-off* é favorável em aplicações que priorizam fidelidade espectral sobre similaridade estrutural pixel a pixel.
- $\lambda = 0,1$ é **insuficiente** para o gap Planet-aerofoto, indicando que a magnitude do gap determina o peso mínimo efetivo da FFL.
- A **avaliação no domínio de frequências** (PSD_L2) é essencial para quantificar ganhos que métricas espaciais (SSIM, PSNR) não capturam.

Como trabalho futuro, propõe-se avaliar pesos intermediários de λ (0,3, 0,5), investigar o efeito de mais dados de treinamento (maior área geográfica) e comparar com outros métodos de superresolução guiada por frequência.

Referências

- [1] L. Jiang, B. Dai, W. Wu e C. C. Loy, “Focal Frequency Loss for Image Reconstruction and Synthesis,” *Proceedings of ICCV*, pp. 13919–13929, 2021. <https://arxiv.org/abs/2012.12821>.
- [2] P. Wolters, F. Bastani e A. Kembhavi, “Zooming Out on Zooming In: Advancing Super-Resolution for Remote Sensing,” *arXiv:2311.18082*, 2023. Código: <https://github.com/allenai/satlas-super-resolution>

- [3] X. Wang *et al.*, “ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks,” *Proceedings of ECCV Workshops*, 2018.
- [4] X. Wang *et al.*, “BasicSR: Open Source Image and Video Restoration Toolbox,” 2022. Disponível em: <https://github.com/XPixelGroup/BasicSR>
- [5] Planet Labs PBC, “Planet Imagery Product Specifications,” 2023. Disponível em: <https://www.planet.com/products/satellite-imagery/>
- [6] Z. Wang, A. C. Bovik, H. R. Sheikh e E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” *IEEE Transactions on Image Processing*, vol. 13, n. 4, 2004.