

**Universidade Federal do Rio Grande do Sul**  
Instituto de Informática  
Programa de Pós-Graduação em Computação

## **Trabalho Final**

**Superresolução no Domínio de Frequências:**

*Fine-tuning* do SATLAS com Focal Frequency Loss  
para Correção do Gap Espectral Planet–Aerofoto

Fotografia Computacional (CMP570)  
Prof. Manuel Menezes de Oliveira Neto  
Orientador: Prof. Dr. Eduardo Simões Lopes Gastal

Aluno: Marcel Fernandes Gomes  
Porto Alegre, 24 de maio de 2026

# 1 Introdução

Imagens de satélite comerciais de média resolução, como as do sensor PlanetScope (resolução espacial de  $\approx 3$  m/pixel), possuem limitações espectrais em relação a fotografias aéreas de alta resolução ( $\approx 0,3$ – $0,5$  m/pixel). Esse *gap* se manifesta na ausência de frequências espaciais altas no espectro de potência (*Power Spectral Density*, PSD) das imagens Planet, quando comparado à PSD de aerofotos. Em aplicações que dependem de detalhe fino — como mapeamento de infraestrutura urbana, inspeção de cobertura vegetal e monitoramento de mudanças — essa diferença limita a utilidade operacional das imagens de satélite.

Superresolução por redes neurais oferece uma abordagem promissora para atenuar esse *gap*. O modelo SATLAS [2] fornece um gerador ESRGAN pré-treinado para o domínio Sentinel-2  $\rightarrow$  NAIP, com fator de escala  $4\times$ . Neste trabalho, realiza-se o *fine-tuning* desse modelo com pares locais Planet  $\rightarrow$  aerofoto, e avalia-se o efeito de adicionar a **Focal Frequency Loss** (FFL) [1] como função de custo auxiliar no domínio espectral.

A FFL foi proposta por Jiang et al. (ICCV 2021) como uma *loss* que pondera erros no espaço de frequências de forma adaptativa: componentes espectrais que o gerador ainda não aprendeu a produzir corretamente recebem maior peso, direcionando o gradiente para a recuperação de frequências difíceis — tipicamente as de alta frequência que o L1 e a *perceptual loss* tendem a suavizar.

## Contribuição

Realiza-se um *ablation study* com três variantes do *fine-tuning*:

- **Baseline:** L1 + Perceptual + GAN (sem FFL)
- **FFL  $\lambda = 0,1$ :** FFL adicionada com peso  $\lambda = 0,1$
- **FFL  $\lambda = 1,0$ :** FFL adicionada com peso  $\lambda = 1,0$

As variantes são comparadas por três métricas: SSIM (estrutural), cPSNR (reconstrutiva, tolerante ao *offset* inter-sensor) e PSD\_L2 (distância espectral ao *ground truth*).

## 2 Fundamentação Teórica

### 2.1 Gap Espectral e Transformada de Fourier

O gap espectral entre imagens Planet e aerofotos pode ser caracterizado pela PSD radial média de cada imagem. Dado uma imagem  $I$  de dimensões  $H \times W$ , sua Transformada Discreta de Fourier 2D (DFT) é:

$$F[u, v] = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} I[x, y] e^{-j2\pi(\frac{ux}{H} + \frac{vy}{W})} \quad (1)$$

A PSD é definida como  $P[u, v] = |F[u, v]|^2$ , e a PSD radial é obtida integrando  $P$  em anéis de frequência  $r = \sqrt{u^2 + v^2}$  (após centralização via *fftshift*). Imagens com maior riqueza de detalhes finos apresentam PSD radial com mais energia nas altas frequências. O *gap* Planet–aerofoto é visível como uma queda mais acentuada da PSD das imagens Planet em relação à PSD da aerofoto nas frequências médias–altas.

## 2.2 Focal Frequency Loss

A FFL opera no domínio de frequências. Dado o gerador  $G$  produzindo  $\hat{I} = G(I_{LR})$  e o *ground truth*  $I_{HR}$ , define-se:

$$\mathcal{L}_{FFL} = \frac{1}{MN} \sum_{u,v} w[u, v] \cdot |F_{\hat{I}}[u, v] - F_{I_{HR}}[u, v]|^2 \quad (2)$$

onde  $F_X$  denota a DFT de  $X$  (calculada via `torch.fft.fft2`), e  $w[u, v]$  é uma máscara de pesos adaptativa. A máscara é atualizada a cada iteração com base no erro espectral acumulado:

$$w[u, v] = \left( 1 - \frac{\hat{F}[u, v] \cdot F_{HR}^*[u, v] + \hat{F}^*[u, v] \cdot F_{HR}[u, v]}{2|\hat{F}[u, v]| |F_{HR}[u, v]| + \epsilon} \right)^\alpha \quad (3)$$

onde  $\alpha$  controla a agressividade do foco (tipicamente  $\alpha = 1$ ). Componentes espectrais bem recuperadas pelo gerador têm  $w \approx 0$ ; as mal recuperadas têm  $w \approx 1$ , recebendo maior gradiente. A loss total de treinamento é:

$$\mathcal{L}_{total} = \mathcal{L}_{L1} + \lambda_{perc} \mathcal{L}_{perc} + \lambda_{GAN} \mathcal{L}_{GAN} + \lambda_{FFL} \mathcal{L}_{FFL} \quad (4)$$

## 2.3 SATLAS e SSR-ESRGAN

O SATLAS é um modelo de superresolução multimodal para imagens de satélite. O gerador utilizado neste trabalho é o SSR\_RRDBNet, uma variante do RRDB [3] adaptada para receber como entrada  $N_s \times 3$  canais (empilhamento temporal de  $N_s$  imagens TCI), produzindo uma saída RGB com fator de escala  $4\times$ . O modelo foi pré-treinado com pares Sentinel-2 ( $N_s = 16$ )  $\rightarrow$  NAIP com 20.000 iterações.

## 2.4 Conexão com os Tópicos de CMP570

Tabela 1: Conexão entre tópicos das aulas e elementos deste trabalho.

| Tópico (CMP570)                  | Papel no projeto                                    |
|----------------------------------|-----------------------------------------------------|
| Aulas 12–13 — Fourier / DFT      | <code>torch.fft.fft2</code> no núcleo da FFL        |
| Aula 14 — Aliasing / Nyquist     | Motivação do gap espectral Planet/Sentinel          |
| Aula 15 — Teorema da Convolução  | Relação PSF $\leftrightarrow$ domínio de frequência |
| Semanas 10–11 — Filtro de Wiener | Baseline clássico de comparação conceitual          |

## 3 Metodologia

### 3.1 Dados

Os dados de entrada são imagens PlanetScope (4 bandas espectrais, 3 m/pixel) sobre uma região do estado do Rio Grande do Sul, obtidas via Planet Explorer. O *ground truth* é uma aerofoto da mesma região com resolução de aproximadamente 0,5 m/pixel, disponibilizada pelo serviço de dados do estado.

O pré-processamento converte os TIFs Planet para chips de  $32 \times 32$  pixels (resolução Planet) alinhados geometricamente com chips de  $128 \times 128$  pixels do *ground truth* (aerofoto), resultando no fator de escala  $4 \times$  esperado pelo modelo. O alinhamento é realizado por reprojeção via GDAL/rasterio, com reamostragem bilinear.

### 3.2 Implementação da FFL no SATLAS

A FFL foi integrada ao SATLAS como módulo adicional, com dois pontos de modificação:

- `ssr/losses/basic_loss.py`: implementação da classe `FocalFrequencyLoss` registrada via `@LOSS_REGISTRY.register()`, compatível com o sistema de *losses* do BasicSR.
- `ssr/models/ssr_esrgan_model.py`: suporte ao campo opcional `ffl_opt` nos YAMLs de configuração, inicializando `self.cri_ffl` e aplicando a loss em `optimize_parameters`. Retrocompatível: sem `ffl_opt`, o comportamento é idêntico ao original.

### 3.3 Configuração do Treinamento

O treinamento foi executado em servidor Linux com GPU Tesla V100-PCIE-32GB, CUDA 12.9. A Tabela 2 resume os hiperparâmetros comuns às três variantes.

Tabela 2: Hiperparâmetros de treinamento (comuns às três variantes).

| Parâmetro                          | Valor                                              |
|------------------------------------|----------------------------------------------------|
| Ponto de partida                   | <code>esrgan_16S2.pth</code> (SATLAS pré-treinado) |
| Número de iterações                | 20.000                                             |
| Batch size                         | 4                                                  |
| Learning rate inicial              | $10^{-4}$ (decaimento em 8k e 16k iters)           |
| Scheduler                          | MultiStepLR ( $\gamma = 0,5$ )                     |
| $N_s$ (imagens Planet por amostra) | 16                                                 |
| Chips de treinamento/validação     | 1.476                                              |
| $\lambda_{L1}$                     | 1,0                                                |
| $\lambda_{perc}$                   | 1,0                                                |
| $\lambda_{GAN}$                    | 0,1                                                |
| $\lambda_{FFL}$ (baseline)         | —                                                  |
| $\lambda_{FFL}$ (ffl_w01)          | 0,1                                                |
| $\lambda_{FFL}$ (ffl_w10)          | 1,0                                                |

### 3.4 Métricas de Avaliação

A avaliação compara as saídas SR de cada variante (iter 20.000) contra o *ground truth* (aerofoto) usando três métricas:

- **SSIM** (*Structural Similarity Index*): mede similaridade em luminância, contraste e estrutura. Maior é melhor.

- **cPSNR** (PSNR com ajuste afim por canal): tolerante ao *offset* radiométrico entre sensores diferentes (Planet vs. aerofoto). Para cada canal  $c$ , encontra-se a transformação afim  $\hat{I}_c \leftarrow a\hat{I}_c + b$  que minimiza o MSE contra o GT, e reporta-se o melhor PSNR. Maior é melhor.
- **PSD\_L2**: distância L2 no  $\log_{10}$  do PSD radial médio entre a imagem SR e o GT, calculada canal a canal:

$$\text{PSD\_L2} = \frac{1}{C} \sum_{c=1}^C \mathbb{E}_r \left[ \left( \log_{10} P_{\hat{I},c}(r) - \log_{10} P_{GT,c}(r) \right)^2 \right] \quad (5)$$

Menor é melhor. Esta é a métrica principal do trabalho, por capturar diretamente o *gap* espectral que a FFL visa corrigir.

## 4 Resultados

### 4.1 Métricas Quantitativas

A Tabela 3 apresenta os resultados do *ablation study* para as três variantes, avaliadas no iter final (20.000).

Tabela 3: Resultados do ablation study — iter 20.000, 1.476 chips.

| Variante            | SSIM $\uparrow$ | cPSNR (dB) $\uparrow$ | PSD_L2 $\downarrow$ |
|---------------------|-----------------|-----------------------|---------------------|
| Baseline (sem FFL)  | 0,6352          | 29,09                 | 0,2574              |
| FFL $\lambda = 0,1$ | 0,6368          | 29,08                 | 0,2638              |
| FFL $\lambda = 1,0$ | 0,6291          | 29,03                 | <b>0,2389</b>       |

O principal resultado é que **FFL  $\lambda = 1,0$  obtém o menor PSD\_L2 (0,2389)**, representando uma redução de 7,2% em relação ao baseline (0,2574). Esse ganho espectral ocorre com um custo pequeno de SSIM ( $\Delta = -0,0061$ ) e de cPSNR ( $\Delta = -0,06$  dB), dentro da faixa de variação esperada. A variante com  $\lambda = 0,1$  não produziu melhora expressiva em nenhuma métrica, indicando que o peso é insuficiente para que o mecanismo focal adaptativo da FFL direcione o treinamento de forma efetiva.

## 4.2 Comparação de Espectros de Potência




Figura 1: PSD radial média (escala log) das três variantes e do *ground truth*. Todas as variantes apresentam déficit de energia nas frequências médias–altas (0,1–0,5 ciclos/pixel) em relação ao GT, caracterizando o gap espectral. A diferença entre variantes é sutil nesta escala; o PSD\_L2 quantifica numericamente a distância ao GT.

A Figura 1 mostra que todas as variantes seguem a mesma tendência: forte energia nas baixas frequências (estruturas grossas) e queda progressiva nas altas frequências. O *ground truth* (aerofoto) mantém maior energia nas frequências intermediárias (detalhes finos como bordas de edifícios, texturas de vegetação), refletindo a maior resolução espacial do sensor aéreo.

## 4.3 Comparação de Métricas por Barra




Figura 2: Comparação de SSIM (esquerda) e PSD\_L2 (direita) entre as três variantes. FFL  $\lambda = 1,0$  apresenta o melhor equilíbrio espectral (menor PSD\_L2) ao custo de leve redução de SSIM.

## 4.4 Discussão

O resultado é consistente com o mecanismo da FFL. O L1 minimiza o erro pixel a pixel, o que penaliza erros em baixas frequências (que têm maior energia e portanto maior contribuição para o MSE) mais do que erros em altas frequências. Isso produz geradores que recuperam bem a estrutura grosseira da cena, mas suavizam as texturas finas. A FFL reequilibra esse gradiente: ao ponderar o erro no domínio de frequências de forma adaptativa, ela direciona o gerador para recuperar as componentes espectrais ainda mal aprendidas — tipicamente as de alta frequência.

O fato de  $\lambda = 0,1$  não produzir melhora sugere que, neste domínio (Planet  $\rightarrow$  aerofoto), o gap espectral é suficientemente grande para exigir um peso maior de FFL. Com  $\lambda = 1,0$ , o gerador efetivamente “sacrifica” algum alinhamento estrutural (queda de SSIM) para recuperar mais energia nas frequências altas (queda de PSD\_L2) — o *trade-off* característico de losses espectrais versus espaciais.

## 5 Conclusões

Este trabalho demonstrou que a adição da Focal Frequency Loss ao *fine-tuning* do SATLAS com dados Planet  $\rightarrow$  aerofoto produz melhora mensurável na fidelidade espectral da superresolução. Os principais achados são:

- **FFL  $\lambda = 1,0$  reduz o PSD\_L2 em 7,2%** em relação ao baseline, confirmando que a loss espectral direciona o gerador para recuperar frequências altas suavizadas pelas losses convencionais.
- **O custo de SSIM é pequeno** ( $\Delta = -0,006$ ), sugerindo que o *trade-off* é favorável em aplicações que priorizam fidelidade espectral sobre similaridade estrutural pixel a pixel.
- $\lambda = 0,1$  **é insuficiente** para o gap Planet-aerofoto, indicando que a magnitude do gap determina o peso mínimo efetivo da FFL.
- **A avaliação no domínio de frequências** (PSD\_L2) é essencial para quantificar ganhos que métricas espaciais (SSIM, PSNR) não capturam.

Como trabalho futuro, propõe-se avaliar pesos intermediários de  $\lambda$  (0,3, 0,5), investigar o efeito de mais dados de treinamento (maior área geográfica) e comparar com outros métodos de superresolução guiada por frequência.

## Referências

- [1] J. Jiang, C. Zhang, M. Harandi, R. Hartley e X. Li, “Focal Frequency Loss for Image Reconstruction and Synthesis,” *Proceedings of ICCV*, 2021.
- [2] B. Bastani *et al.*, “SatlasPretrain: A Large-Scale Dataset for Remote Sensing Image Understanding,” *Proceedings of ICCV*, 2023. Código disponível em: <https://github.com/allenai/satlas-super-resolution>
- [3] X. Wang *et al.*, “ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks,” *Proceedings of ECCV Workshops*, 2018.

- [4] X. Wang *et al.*, “BasicSR: Open Source Image and Video Restoration Toolbox,” 2022. Disponível em: <https://github.com/XPixelGroup/BasicSR>
- [5] Planet Labs PBC, “Planet Imagery Product Specifications,” 2023. Disponível em: <https://www.planet.com/products/satellite-imagery/>
- [6] Z. Wang, A. C. Bovik, H. R. Sheikh e E. P. Simoncelli, “Image Quality Assessment: From Error Visibility to Structural Similarity,” *IEEE Transactions on Image Processing*, vol. 13, n. 4, 2004.